

CYCLE 3 統計分析報告與技術文件

對應專案：第八組青少年飲酒行為與 BMI 百分位關聯性研究

本文件依據第八組所編寫之 Jupyter Notebook 實作程式碼與執行結果，完整紀錄並梳理以下核心統計架構，包含變數重編碼、組別定義、反應變數定義、統計方法選擇以及假設檢定考量。

1. 變數重編碼 (Variable Coding)

原始資料集採用美國疾病管制與預防中心（CDC）之青少年危險行為調查（YRBS 2007）。為了探討飲酒行為之核心效果，研究針對原始行為特徵進行了二分化重編碼（Recoding）：

- **原始特徵變數**：CurrentAlcoholUse（代表過去30天內的飲酒天數代碼）。
- **編碼規則**：根據文件規範，代碼 2 至 7 代表過去30天內有不同天數的飲酒行為，統一編碼為 1；代碼 1 代表過去30天內0天飲酒（即無飲酒），編碼為 0。其餘空白或無效填答代碼則予以排除。

```
def recode_alcohol(code):  
    if 2 <= code <= 7:  
        return 1 # 有飲酒 (Success / Exposed)  
    elif code == 1:  
        return 0 # 無飲酒 (Failure / Comparison)  
    else:  
        return np.nan # 排除其他無效填答
```

2. 組別定義 (Group Definition)

經由上述重編碼程序後，樣本被嚴格劃分為兩個獨立之對比研究組別，並同時排除組別或反應變數中含有缺失值（NaN）的無效觀測值：

- **非飲酒組 (Control Group / Comparison Group)**：代碼為 0.0。經過資料清洗與過濾後，最終有效樣本數為 6,449 人。
- **飲酒組 (Exposed Group / Success Group)**：代碼為 1.0。經過資料清洗與過濾後，最終有效樣本數為 5,394 人。

3. 反應變數定義 (Response Variable Definition)

本研究之反應變數（Response Variable，即依變項）為青少年的體重指標百分位數：

- **變數名稱：**BMIPCT (BMI Percentile)。
- **變數性質：**連續型變數（Continuous Variable），代表個體在同性別與同年齡層中所處的 BMI 百分位位置。
- **各組描述性統計摘要：**

組別 (Alcohol_Group)	樣本數 (n)	平均數 (Mean)	標準差 (Std)	中位數 (Median)
0.0 (非飲酒組)	6,449	64.7060	27.8447	70.3192
1.0 (飲酒組)	5,394	64.7994	26.9782	69.8717

- **原始平均值差異：**飲酒組平均 BMI 百分位減去非飲酒組平均 BMI 百分位之點估計值（Point Estimate）為 $\Delta\bar{x} = 0.0934$ ，顯示兩組表面數據的差異極其微小。

4. 統計方法選擇 (Method Choice)

為檢定「飲酒組」與「非飲酒組」之間的平均 BMI 百分位數是否存在顯著之統計學差異，本研究採用了 **Welch's t-test**（韋爾奇兩獨立樣本 t 檢定）。

- **選擇理由：**傳統 Student's t-test 要求兩組樣本的母體變異數必須相等（Homoscedasticity）；而 Welch's t-test 在計算自由度時引入了變異數修正，當兩組樣本數不相等且變異數可能存在差異時，此方法能提供更穩健、更精確的 p 值。
- **檢定實作：**於 Python 中調用 `scipy.stats.ttest_ind(group1, group0, equal_var=False)` 執行。

5. 假設檢定與考量 (Assumptions Considered)

在進行 Welch's t-test 時，研究團隊設立並評估了以下假設與統計邊界條件：

- **統計假設設立：**
 - 虛無假設 (H_0)： $\mu_1 = \mu_0$ （飲酒組與非飲酒組的青少年平均 BMI 百分位無顯著差異）。
 - 對立假設 (H_1)： $\mu_1 \neq \mu_0$ （飲酒組與非飲酒組的青少年平均 BMI 百分位存在顯著差異）。
- **顯著水準：**設定為 $\alpha = 0.05$ 。
- **檢定數據結果：**
 - t 統計量 (t-statistic)：0.1849

- p 值 (p-value) : 0.8533
- 95% 信賴區間 (95% Confidence Interval) : [-0.90, 1.08]

統計學合理解釋與結論：

由於 p 值 (0.8533) 遠大於顯著水準 $\alpha = 0.05$ ，因此我們無法拒絕虛無假設 (Fail to reject H_0)。此外，兩組平均值的差異之 95% 信賴區間包含了 0，這在統計學上進一步證實了：在該青少年族群中，當前的飲酒行為與 BMI 百分位之間並無顯著關聯，即飲酒並非影響該族群體重指標的核心主要因素。